盛子轩

电话：13972356282｜微信：segzix_work2026

邮箱：shengzixuan.work@foxmail.com



教育背景

中国科学院大学计算技术研究所｜硕士在读 2025.09 — 至今

微处理器中心架构组｜研究方向：关键系统设计与 AI 系统软件设计

中国科学院大学｜计算机科学与技术｜本科 2021.09 — 2025.06

GPA：3.92/4.0｜专业排名：6/102

荣誉：2022–2023 年度二等奖学金；2023–2024 年度一等奖学金；2024–2025 年度三好学生；

技术能力

- 训推框架 与基本算法：了解 PyTorch、FSDP、Megatron 框架，以及 vLLM、SGLang 等推理框架的基本原理与使用方式；Transformer 及 MLA、DSA 等常见 LLM 结构，熟悉量化与推测解码等推理优化技术。
- GPU 编程与算子开发：熟悉 GPU 编程、CUDA 及 DSL（如 Triton），具备 GPU Kernel 开发经验。
- 编程与系统：熟悉 C/C++、Python 及 Linux 开发，了解系统并发编程，熟悉双核调度、虚拟内存、文件系统及写时复制。
- 体系结构：熟悉 CPU、GPU、Cache、虚拟内存、NUMA、PCIe 与 RDMA 等软硬件协同基础。
- AI 辅助开发：熟悉 Vibe Coding 开发流程，能够使用 Codex 进行需求拆解、代码生成、调试与测试；了解 MCP 协议及工具接入方式，能够结合项目上下文开展开发迭代与代码审查。

实习经历

SMARTX｜云计算与虚拟化研发实习 2025.11 — 2026.06

- QEMU postcopy 开发与在线快照：分析并实现基于 UFFD-WP 的后台快照与写保护机制；16GB、10%–90% 四组负载平均停机 97ms、快照阶段 TPS 保持率 81.2%，对应后训练 checkpoint 对一致性与在线吞吐的双重要求。
- 大内存按需恢复：验证页索引、userfaultfd 缺页线程与 blockdev/iSCSI 恢复链路；4GB/8GB hugepage 场景较普通文件恢复快约 20%–24%，覆盖推理服务内存按需加载和任务快速启动等关键环节。

龙芯｜RDMA 分布式系统研发实习 2024.09 — 2025.04

- 异步通信架构：为 M-JIAJIA 接入 UDP / RDMA，基于 RDMA CM、内存注册与 RC Send 实现通信，以消息队列解耦收发处理线程，采用异步事件通知；将通信流水线拆分为可并行执行的任务阶段，适用于 rollout 与训练端的异步数据交换，体现分布式训练与推理通信层所需的低延迟优化能力。
- 分布式访存性能：双机 RDMA 较千兆 UDP 的 Water-1728、LU-2048 总耗时降低 42.52%、64.72%；结合远程预取减少取页与同步等待，形成面向后训练集群通信瓶颈的分析思路。

在校项目

veRL / AReaL 异构硬件上的异步 post-training 与推测解码加速

- AReaL/veRL 同步异步调研实验与资源分配：分析昇腾 NPU 上 GRPO 训练流水线，调研相关的异步实验论文在八卡流水线上实验同步和异步的 post-training，通过异步取得 post-training 的加速，同时调整推理 / 训练资源配置由 2/6 为 4/4 ，平均步耗时缩短 25.51%。
- 推测解码加速：通过将推测解码应用于 rollout 环节，对 draft model 进行实时更新，克服 rollout 的瓶颈问题，加速了整个 post-training 的流程。

语言与技能

英语：CET-6 580 分，具备英文学术论文阅读与写作能力。